Считываем данные, делаем выборку параметров, дамми-переменные и классификация методом опорных векторов(SVM)

```
#Импорт модулей
import pandas as pd
import numpy as np
from sklearn.model selection import train test split, cross val score
from sklearn.svm import SVC
from sklearn.metrics import precision score, recall score, f1 score
# Загрузка данных
exam df = pd.read csv('StudentsPerformance.csv')
#Выберем необходимые нам параметры
exam df = exam df.loc[:, exam df.columns.isin(['gender', 'parental
level of education', 'writing score', 'reading score', 'math
score', 1)1
#Смотрим на наши данные
print(exam df)
#Удаление пустых значений (если таковы имеются)
exam df = exam df.dropna()
# Выделение целевого признака ( writing score (выше среднего значения
— класс 0, ниже или совпадает — класс 1) )
exam df['writing score above avg'] = (exam df['writing score'] >
exam df['writing score'].mean()).astype(int)
# Удаление целевого признака
exam df.drop('writing score', axis=1, inplace=True)
# Создание дамми-переменных с помощью one-hot-encoding
#Пол (Мужчина - 1, женщина - 0)
exam_df['gender'] = np.where(exam df['gender'] == 'male' , 0, 1)
#Уровень образования (Бакалавр - 1, Магистр - 2, Аспирант - 3, High
school - 4, Колледж - 5, Some high school - 6)
exam_df['parental level of education'] = np.where(exam_df['parental
level of education'] == 'bachelor\'s degree' ,
                                                  1, exam df['parental
level of education'l)
exam df['parental level of education'] = np.where(exam df['parental
level of education'] == 'master\'s degree' ,
                                                  2, exam df['parental
level of education'])
exam df['parental level of education'] = np.where(exam df['parental
level of education'] == 'associate\'s degree' ,
```

```
3, exam df['parental
level of education'l)
exam_df['parental level of education'] = np.where(exam_df['parental
level of education'] == 'high school' ,
                                                   4, exam df['parental
level of education'])
exam df['parental level of education'] = np.where(exam df['parental
level of education'] == 'some college' ,
                                                    5, exam df['parental
level of education'l)
exam df['parental level of education'] = np.where(exam df['parental
level of education'] == 'some high school' ,
                                                    6, exam df['parental
level of education'l)
df encoded = exam df
# Разделение на обучающую и тестовую выборки
X_training, X_testing, y_training, y_testing =
train_test_split(df_encoded.drop('writing_score_above_avg', axis=1),
df encoded['writing score above avg'],
                                                      test size = 0.3,
                                                      random state = 42)
# Создание и обучение модели SVM
clf = SVC(kernel='linear', random_state=42)
clf.fit(X training, y training)
# Получение прогнозов на тестовой выборке
y pred = clf.predict(X testing)
# Оценка точности классификатора с помощью метрик precision, recall и
precision = precision score(y testing, y pred)
recall = recall score(y testing, y pred)
f1 = f1 score(y testing, y pred)
     gender parental level of education math score
                                                      reading score
0
          1
                                                  72
                                                                  72
                                                                     \
                                       5
          1
                                                  69
1
                                                                  90
2
                                       2
          1
                                                  90
                                                                  95
3
                                       3
          0
                                                  47
                                                                  57
                                       5
                                                                  78
4
                                                  76
          0
                                                                 . . .
                                     . . .
                                                  . . .
995
                                       2
                                                  88
                                                                  99
          1
996
          0
                                       4
                                                  62
                                                                  55
997
          1
                                       4
                                                  59
                                                                  71
                                       5
998
          1
                                                  68
                                                                  78
                                       5
999
          1
                                                  77
                                                                  86
```

```
writing_score_above_avg
0
1
                           1
2
                           1
3
                           0
4
                           1
995
                           1
996
                           0
                           0
997
998
                           1
999
[1000 rows x 5 columns]
Итог SVM
#Результат
print( "accuracy:"+str(np.average(cross val score(clf, X testing,
y testing, scoring= 'accuracy'))))
             "f1:"+str(np.average(cross_val_score(clf, X_testing,
print(
y testing, scoring= 'f1'))))
print("precision:"+str(np.average(cross val score(clf, X testing,
y_testing, scoring= 'precision'))))
        "recall:"+str(np.average(cross val score(clf, X testing,
print(
y testing, scoring= 'recall'))))
accuracy: 0.90666666666668
f1:0.9063845372228225
precision: 0.9185974945533768
recall:0.9
Классификация с помощью классификатора типа Случайный лес(Random
forest)
#Подключаем модуль
from sklearn.ensemble import RandomForestClassifier
# разделение данных на обучающую и тестовую выборки
training data, testing data, training labels, testing labels =
train test split(
    df encoded.drop("writing score above avg", axis=1),
df encoded["writing score above avg"], test size=0.2, random state=42)
# построение классификатора
rf = RandomForestClassifier(n estimators=100, random state=42)
rf.fit(training data, training labels)
# оценка качества классификатора на тестовой выборке
```

```
print( "accuracy:"+str(np.average(cross val score(rf, X testing,
v testing, scoring= 'accuracy'))))
             "f1:"+str(np.average(cross_val_score(rf, X_testing,
print(
y testing, scoring=
                    'f1'))))
print("precision:"+str(np.average(cross_val_score(rf, X_testing,
y testing, scoring= 'precision'))))
print( "recall:"+str(np.average(cross val score(rf, X testing,
y_testing, scoring= 'recall'))))
accuracy: 0.896666666666667
f1:0.896499688318275
precision: 0.9037908029843514
recall:0.893333333333333333
Перебираем различные гиперпараметры для Random Forest с помощью
GridSearch
#Делаем импорт ещё пары модулей необходимых нам
from sklearn.metrics import classification report
from sklearn.model selection import GridSearchCV
# определение диапазона значений для перебора
param grid = {
    "n estimators": [50, 100, 150, 200],
    "max_depth": [None, 5, 10, 15],
    "min_samples_split": [2, 5, 10],
    "min samples_leaf": [1, 2, 4],
    "max_features": ["sqrt", "log2"],
}
# создание экземпляра класса GridSearchCV
grid search rf = GridSearchCV(RandomForestClassifier(random state=42),
param grid, cv=3, n jobs=-1)
# запуск GridSearchCV
grid search rf.fit(training data, training labels)
# Оцениваем качество классификации
print(classification report(y testing, y pred))
print( "accuracy:"+str(np.average(cross val score(grid search rf,
X testing, y testing, scoring= 'accuracy'))))
             "f1:"+str(np.average(cross val score(grid_search_rf,
print(
X_testing, y_testing, scoring= 'f1'))))
print("precision:"+str(np.average(cross val score(grid search rf,
X testing, y testing, scoring= 'precision'))))
        "recall:"+str(np.average(cross_val_score(grid_search_rf,
print(
X testing, y testing, scoring= 'recall'))))
```

```
precision recall f1-score
                                             support
           0
                  0.89
                            0.94
                                      0.91
                                                 150
                   0.94
                            0.88
                                      0.91
                                                 150
           1
                                      0.91
                                                 300
   accuracy
                  0.91
                            0.91
                                      0.91
                                                 300
   macro avg
                  0.91
                            0.91
                                      0.91
                                                 300
weighted avg
f1:0.8939327871944979
precision: 0.8978257032692516
recall:0.893333333333333333
Лучшими гиперпараметрами оказались:
print("Best parameters:", grid search rf.best params )
Best parameters: {'max depth': 5, 'max features': 'sgrt',
'min samples leaf': 2, 'min samples split': 2, 'n estimators': 150}
Различные комбинации гиперпараметров для случайного дерева с шагом
50 и 10 в параметре n_estimators и вывод их лучших значений
from sklearn.ensemble import RandomForestClassifier
from sklearn.model selection import GridSearchCV
from sklearn.metrics import accuracy score, recall score, f1 score
# Различные комбинации гиперпараметров для случайного дерева с шагом
50 в параметре n estimators
param grid 50 = \{
    'n estimators': [i for i in range(150, 301, 50)]
}
rfc 50 = RandomForestClassifier(random state=42)
grid search 50 = GridSearchCV(estimator=rfc 50,
param grid=param grid_50, cv=5)
grid search 50.fit(X training, y training)
# Вывод лучших значений для шага 50 в параметре n estimators
print("Best n estimators for step 50: ",
grid search 50.best params ['n estimators'])
# Прогноз на основе данных тестирования с помощью случайного дерева с
шагом 50 в параметре n estimators
rfc 50 pred = grid search 50.predict(X testing)
# Точность, отзыв и оценку F1, используя метод случайный лес с шагом
50
rfc 50 accuracy = accuracy score(y testing, rfc 50 pred)
```

```
rfc 50 recall = recall score(y testing, rfc 50 pred,
average='weighted')
rfc_50_f1_score = f1_score(y_testing, rfc_50_pred, average='weighted')
print("Accuracy for step 50: ", rfc_50_accuracy)
print("Recall for step 50: ", rfc_50_recall)
print("F1 Score for step 50: ", rfc_50_f1_score)
# Различные комбинации гиперпараметров для случайного дерева с шагом
10 в параметре n estimators
param grid 10 = {
    'n_estimators': [i for i in range(150, 301, 10)]
}
rfc 10 = RandomForestClassifier(random state=42)
grid search 10 = GridSearchCV(estimator=rfc 10,
param grid=param grid 10, cv=5)
grid search 10.fit(X training, y training)
# Вывод лучших значений для шага 10 в параметре n estimators
print("Best n estimators for step 10: ",
grid search 10.best params ['n estimators'])
# Прогноз на основе данных тестирования с помощью случайного дерева с
шагом 10 в параметре n estimators
rfc 10 pred = grid search 10.predict(X testing)
# Точность, отзыв и оценку F1, используя метод случайный лес с шагом
10
rfc 10 accuracy = accuracy score(y testing, rfc 10 pred)
rfc 10_recall = recall_score(y_testing, rfc_10_pred,
average='weighted')
rfc_10_f1_score = f1_score(y testing, rfc 10 pred, average='weighted')
print("Accuracy for step 10: ", rfc_10_accuracy)
print("Recall for step 10: ", rfc 10 recall)
print("F1 Score for step 10: ", rfc_10_f1_score)
Best n estimators for step 50:
Accuracy for step 50: 0.9
Recall for step 50: 0.9
F1 Score for step 50: 0.899888765294772
Best n estimators for step 10:
Accuracy for step 10:
Recall for step 10: 0.9
F1 Score for step 10: 0.899888765294772
В итоге классификатор типа SVM справился чуть лучше(и быстрее)
```